# 基于 RAG 与规则核验的商业合同审查 Agent

## 条款识别与证据可追溯性研究

> 从商业合同中识别关键约定，
> 形成有原文依据、可人工复核的初审结果。

胡杨 · 严江慧 · 叶菁菁 · 许舒琳 · 王莎莎 · 汤昊臻 · 肖鹏 · 郑伟宾



# 业务场景

把目标企业的合同约定转化为买方可追问、可复核的尽调事项

**使用者：投资方 / 收购方尽调人员**

**时点：交易前商业合同初筛**

### 01 输入合同资料

目标企业已有的
服务、供货、许可等商业合同

### 02 执行初筛

定位指定条款，整理主体与条件
按预设政策检查并保留原文

### 03 输出复核事项

补充核查、询问目标企业
升级法务或交易团队进一步判断

## 具体业务问题

**续约期限** 续约后还持续多久？

**退出通知** 不希望续约，需提前多久通知？

**终止安排** 主体、条件与交易影响是否明确？

内容分散、条件与例外易漏，初审需保留证据；对应信息不对称下的搜寻、理解与核验成本。

# 研究问题与任务边界

41 类识别任务、已配置的政策检查、人工复核分流分别评价

**CUAD**
数据集

**510**
份英文商业合同

**41**
类条款审查类别

### 研究问题

相比人工全量审查与单次 LLM，Agent 在条款识别、政策执行、证据可靠性和处理时间上表现如何?

**条款与信息识别**

41 类任务
输出答案、逐字引文与位置

→

**政策检查**

仅检查已配置明确政策的类别
触发 / 未触发
不适用 / 无法确认

→

**复核分流**

关注事项与不确定结果
输出复核清单及原因

CUAD 原文用于审查，人工标注用于评价；510 是总体规模，最终实验样本量另行记录。

条款存在不等于风险成立；CUAD 标注不直接提供本项目政策下的风险等级。

# Agent 总体架构

Agent控制器组织任务，内部 LLM 抽取事实，两个业务工具返回反馈



# RAG 检索与 LLM 抽取

每一步都产出可传递的结果，引用统一锚定到冻结文本

**RAGTool：提供可定位的相关上下文**

**内部 LLM：整理合同事实**

### 01 合同解析与分块

提取文本、保留页码和字符位置；按条款结构切分

产出 **冻结文本 + 位置基准**

### 02 Embedding+BM25

Embedding匹配不同说法，BM25匹配不同合同关键词

产出 **合同内可检索片段**

### 03 融合排序+补充召回

使用RRF融合两路排名，保留强关键字匹配。补充合同开头信息、去除重叠片段

产出 **相关片段 + 定位信息**

### 04 证据定位与核验

保留原文引用、页码和起始位置；检查语义支持；证据不足时标为不确定

产出 **答案 + 引用 + 处理状态**

| 贯穿案例 | 类别答案 | 证据要求 | 后续动作 |
| --- | --- | --- | --- |
| Renewal Term | 5 years | 合同逐字引文 + 字符位置<br>状态：已完成 / 未完成 / 错误 | 交由证据核验 |

检索分数仅表示片段相关；答案与引用是否可靠，需要下一步的位置、语义与覆盖检查。

# 证据核验与规则判断

先确认事实有依据，再按固定政策形成关注提示

## 证据核验

| | |
|---|---|
| **位置核验** | 引文是否与指定位置的冻结原文一致? |
| **语义核验** | 引文是否真正支持抽取的类别答案? |
| **否定覆盖检查** | “未发现条款”是否有足够搜索覆盖? |

语义反例：“每次续约一年”不能支持“退出续约需提前一年通知”。

**核验通过**

## 规则判断：续约期限示例

**合同事实：5 年 = 60 个月**

模拟政策：单次续约超过 12 个月

**程序比较：60 > 12**

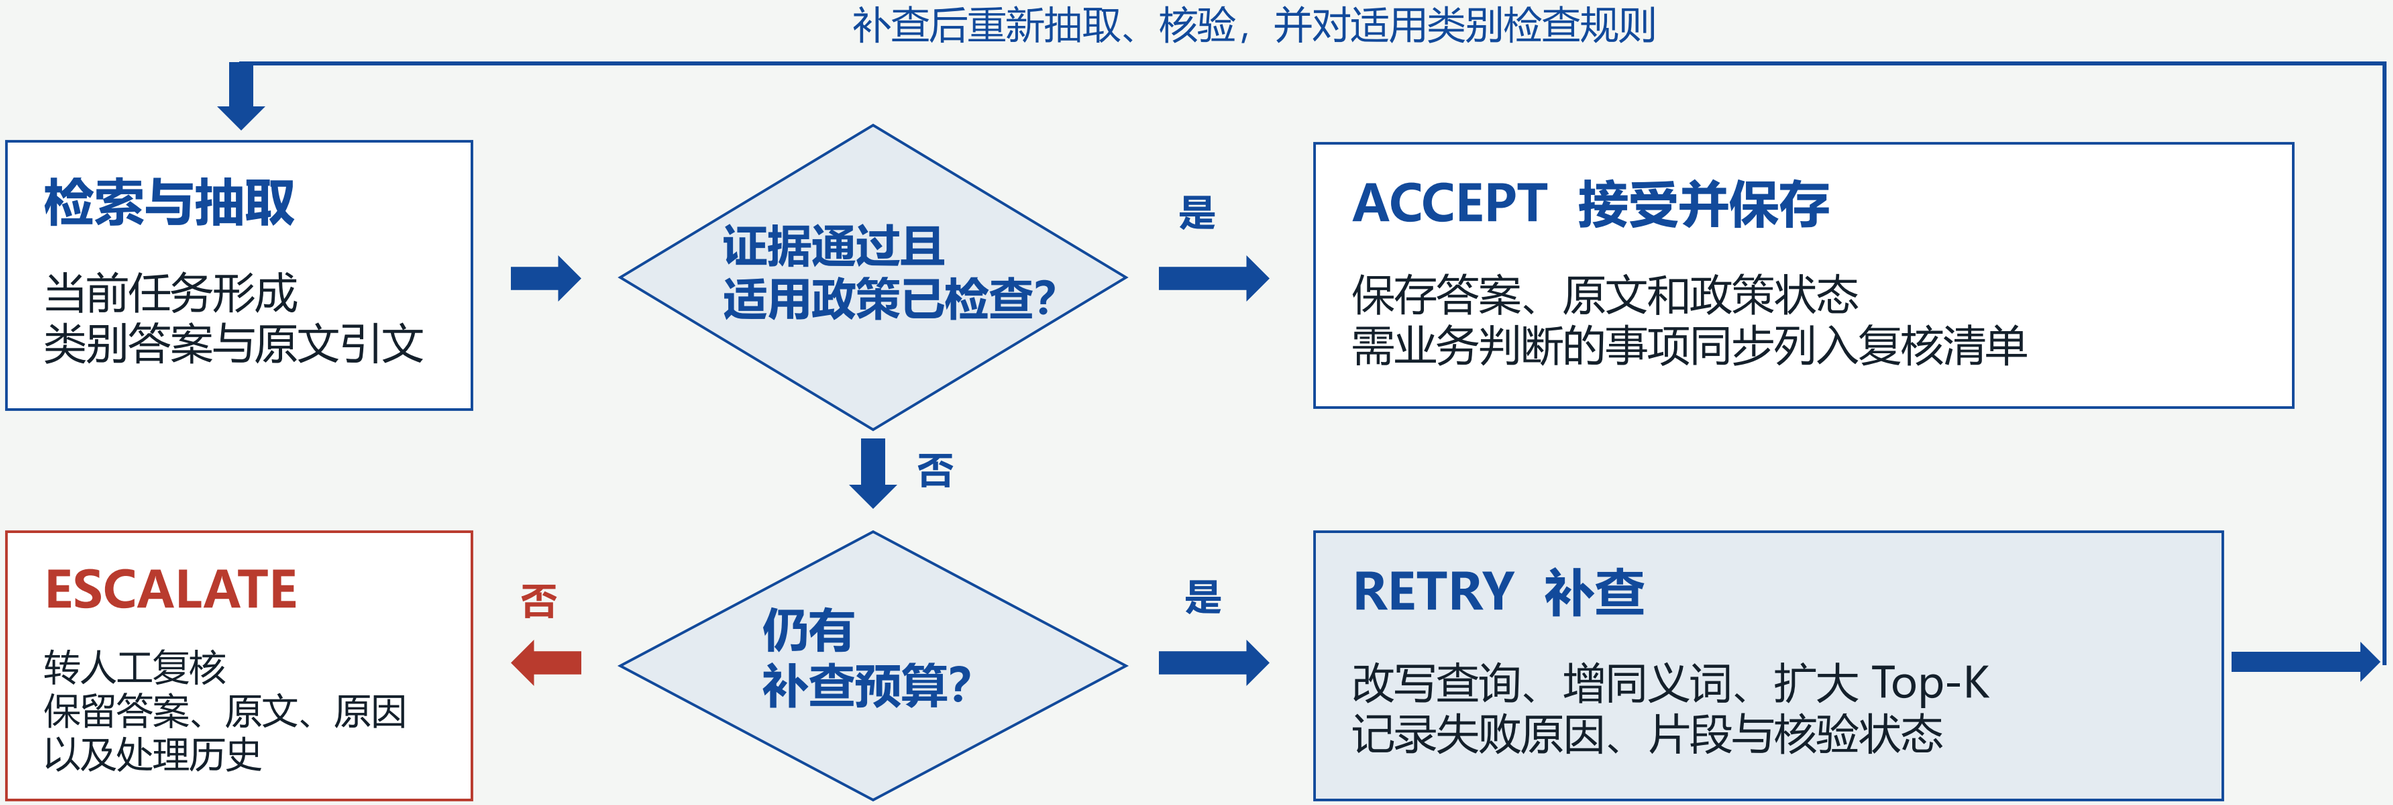
**触发关注，并按配置要求人工复核**

核验失败：进入补查或复核分支；事实或政策条件不足：保留“无法确认”。

目前六类规则：适用法律、续约期限、退出通知期限、保险义务、审计权、无因终止；阈值为模拟政策，非完整实测。

# 接受、补查与人工复核

核验反馈决定下一步，补查有预算，不确定事项有人工出口




每项任务独立记忆；首次尝试后默认最多补查两次。已触发的关注事项保留，补查用于完善证据。

# 运行案例

RISE Education 服务协议：用续约期限串起证据与政策提示

## 真实检索与位置核验

**CUAD 开发侧样本：RISE Education 服务协议 • 第 13 条**

This Agreement shall be renewed automatically for another five (5) years upon the expiration unless the Parties confirm, in writing, the termination of this Agreement.

**13414**

原始位置核验通过，可回查冻结文本

**位置偏移 +5**

核验失败，拒绝直接使用该引用

## 报告片段 • 政策为方法演示

| 报告字段 | 内容 |
| --- | --- |
| 审查类别 | Renewal Term |
| 识别结果 | 续约五年 |
| 合同原文 | 左侧第 13 条逐字引文 |
| 证据位置 | 起始字符 13414 |
| 政策结果 | 60 > 12，触发关注 |
| 人工复核 | 确认续约条件与交易影响 |

阶段演示：真实检索与位置核验；抽取含接口示例，语义通过分支为桩模型，政策比较仅说明方法。

# 三组对照实验设计

同一合同、同一任务和政策，比较完整方案的综合表现

**统一输入：同一批合同全文、41 类任务、冻结政策与同一份输出模板**

## 人工全量审查

人工阅读全文
记录事实、证据、政策结果
记录待确认事项和审查耗时

## 单次 LLM 判断

一次模型调用完成审查
不进行工具反馈补查
保存未经修改的原始输出

## 我们的 Agent

检索、抽取、核验与规则判断
有限补查、状态记录与汇总
输出人工复核清单

**独立参考答案与统一评价：条款识别、政策执行、引用支持、单合同耗时与调用成本**

控制：模型组尽量使用相同底模与参数；记录人工背景并控制样本熟悉度；上下文不足不静默截断。

待检验：相对人工能否节省时间；相对单次 LLM 能否改善质量。三组比较不单独证明某组件的贡献。

# 评价指标与失败场景

把质量、可靠性与成本转成可计算指标，并观察异常处理

| 评价维度 | 指标与口径 | 参考依据 |
| --- | --- | --- |
| 条款识别 | 精确率、召回率、F1；预先明确片段匹配或重叠判据 | CUAD 标注，必要时核查额外片段 |
| 政策执行 | 触发一致率；记录误触发、漏触发与无法确认 | 冻结政策与独立核对结果 |
| 证据可靠性 | 引用支持率；另记应提供但缺失的引用 | 原文位置与独立语义核查 |
| 处理代价 | 单合同总耗时；模型组另记调用次数 | 统一审查与运行日志 |

**引用支持率 = 真实可验证且支持结论的引用数 ÷ 全部输出引用数**

**条件分散 / 漏检**

观察是否发现覆盖不足并补查

**位置错位 / 错引**

观察是否拒绝直接接受

**模型或工具异常**

观察是否保留无法确认与原因

**合同嵌入干扰指令**

观察是否仍按审查要求处理

未输出引用和“无法确认”分别统计，不能当作正确或直接剔除；完整三组实验仍待运行。

共同场景使用相同合同输入；位置错位与模型不可用另作 Agent 专项故障测试。

# 风险治理与研究局限

说明设计措施能解决什么，以及仍然不能保证什么

| 风险或局限 | 设计措施 | 仍需说明的边界 |
| --- | --- | --- |
| 合同中的干扰指令 | 将合同作为待审数据，限制工具权限 | 需要通过注入测试验证 |
| 引用正确但解释错误 | 位置与语义分别核验 | 语义模型仍可能误判 |
| 检索遗漏导致错误否定 | 覆盖检查、补查并保留无法确认 | 锚定词覆盖属于启发式依据 |
| 审核政策来源不清 | 记录政策版本、阈值与提示等级 | 模拟政策不代表普遍法律或市场标准 |
| 关注事项需业务判断 | 保留人工复核出口与原文依据 | 标记复核不代表人工已完成审核 |
| 样本代表性有限 | 记录来源、筛选规则与排除情况 | 英文公开披露合同不能直接推广至其他群体 |

研究结论限定于所选样本、任务、模型与政策配置，并同时报告失败情况与处理成本。

# 目前进展与后续计划

从已提交的模块基础推进到真实模型运行与完整比较

| 工作模块 | 当前可说明的成果 | 状态边界 |
| --- | --- | --- |
| 问题与数据 | 场景说明、数据结构与使用边界、候选样本清单 | 已提交基础材料 |
| 理论与设计 | 理论框架、方法依据、研究假设与参考文献 | 已提交设计材料 |
| Agent | 架构、接口、状态、重试与人工复核流程 | 已形成设计 |
| RAG | 检索核验工具、测试脚本、案例与初步评测报告 | 模块成果 |
| 规则 | 六类政策检查代码、配置与接口说明 | 模块成果 |
| 实验与整合 | 已有实验设计，需统一三组并完成系统运行与比较 | 完整联调与三组实验待完成 |

## 排期与可检查交付

**11/7**
**Presentation**
PPT、讲稿
阶段案例、状态表

**11/8—15**
**41 类配置与联调**
覆盖清单
真实报告、日志

**11/16—23**
**冻结样本与三组实验**
原始输出、计时
参考答案、指标表

**11/24—26**
**误漏报与复核分析**
结果图表
完整案例、失败分析

**11/27—30**
**论文、展示与复现**
论文、运行说明、
文件清单

最终回答：初筛质量、证据可靠性与处理成本如何权衡，哪些事项仍需要人工判断。