基于 RAG 与规则核验的商业合同审查 Agent

条款识别与证据可追溯性研究

> 从商业合同中识别关键约定，
> 形成有原文依据、可人工复核的初审结果。

胡杨 · 严江慧 · 叶菁菁 · 许舒琳 · 王莎莎 · 汤昊臻 · 肖鹏 · 郑伟宾



业务场景

把目标企业的合同约定转化为买方可追问、可复核的尽调事项

使用者：投资方 / 收购方尽调人员

时点：交易前商业合同初筛

01 输入合同资料

目标企业已有的
服务、供货、许可等商业合同

02 执行初筛

定位指定条款，整理主体与条件
按预设政策检查并保留原文

03 输出复核事项

补充核查、询问目标企业
升级法务或交易团队进一步判断

具体业务问题

续约期限 续约后还持续多久？

退出通知 不希望续约，需提前多久通知？

终止安排 主体、条件与交易影响是否明确？

内容分散、条件与例外易漏，初审需保留证据；对应信息不对称下的搜寻、理解与核验成本。

研究问题与任务边界

41 类识别任务、已配置的政策检查、人工复核分流分别评价

CUAD
数据集

510
份英文商业合同

41
类条款审查类别

研究问题

相比人工全量审查与单次 LLM，Agent 在条款识别、政策执行、证据可靠性和处理时间上表现如何?

条款与信息识别

41 类任务
输出答案、逐字引文与位置

→

政策检查

仅检查已配置明确政策的类别
触发 / 未触发
不适用 / 无法确认

→

复核分流

关注事项与不确定结果
输出复核清单及原因

CUAD 原文用于审查，人工标注用于评价；510 是总体规模，最终实验样本量另行记录。

条款存在不等于风险成立；CUAD 标注不直接提供本项目政策下的风险等级。

Agent 总体架构

Agent控制器组织任务，内部 LLM 抽取事实，两个业务工具返回反馈



RAG 检索与 LLM 抽取

每一步都产出可传递的结果，引用统一锚定到冻结文本

RAGTool：提供可定位的相关上下文

内部 LLM：整理合同事实

01 合同解析与分块

提取文本、保留页码和字符位置；按条款结构切分

产出 **冻结文本 + 位置基准**

02 Embedding+BM25

Embedding匹配不同说法，BM25匹配不同合同关键词

产出 **合同内可检索片段**

03 融合排序+补充召回

使用RRF融合两路排名，保留强关键字匹配。补充合同开头信息、去除重叠片段

产出 **相关片段 + 定位信息**

04 证据定位与核验

保留原文引用、页码和起始位置；检查语义支持；证据不足时标为不确定

产出 **答案 + 引用 + 处理状态**

贯穿案例	类别答案	证据要求	后续动作
Renewal Term	5 years	合同逐字引文 + 字符位置 状态：已完成 / 未完成 / 错误	交由证据核验

检索分数仅表示片段相关；答案与引用是否可靠，需要下一步的位置、语义与覆盖检查。

证据核验与规则判断

先确认事实有依据，再按固定政策形成关注提示

证据核验

位置核验	引文是否与指定位置的冻结原文一致?
语义核验	引文是否真正支持抽取的类别答案?
否定覆盖检查	“未发现条款”是否有足够搜索覆盖?

语义反例：“每次续约一年”不能支持“退出续约需提前一年通知”。

核验通过

规则判断：续约期限示例

合同事实：5 年 = 60 个月

模拟政策：单次续约超过 12 个月

程序比较：60 > 12

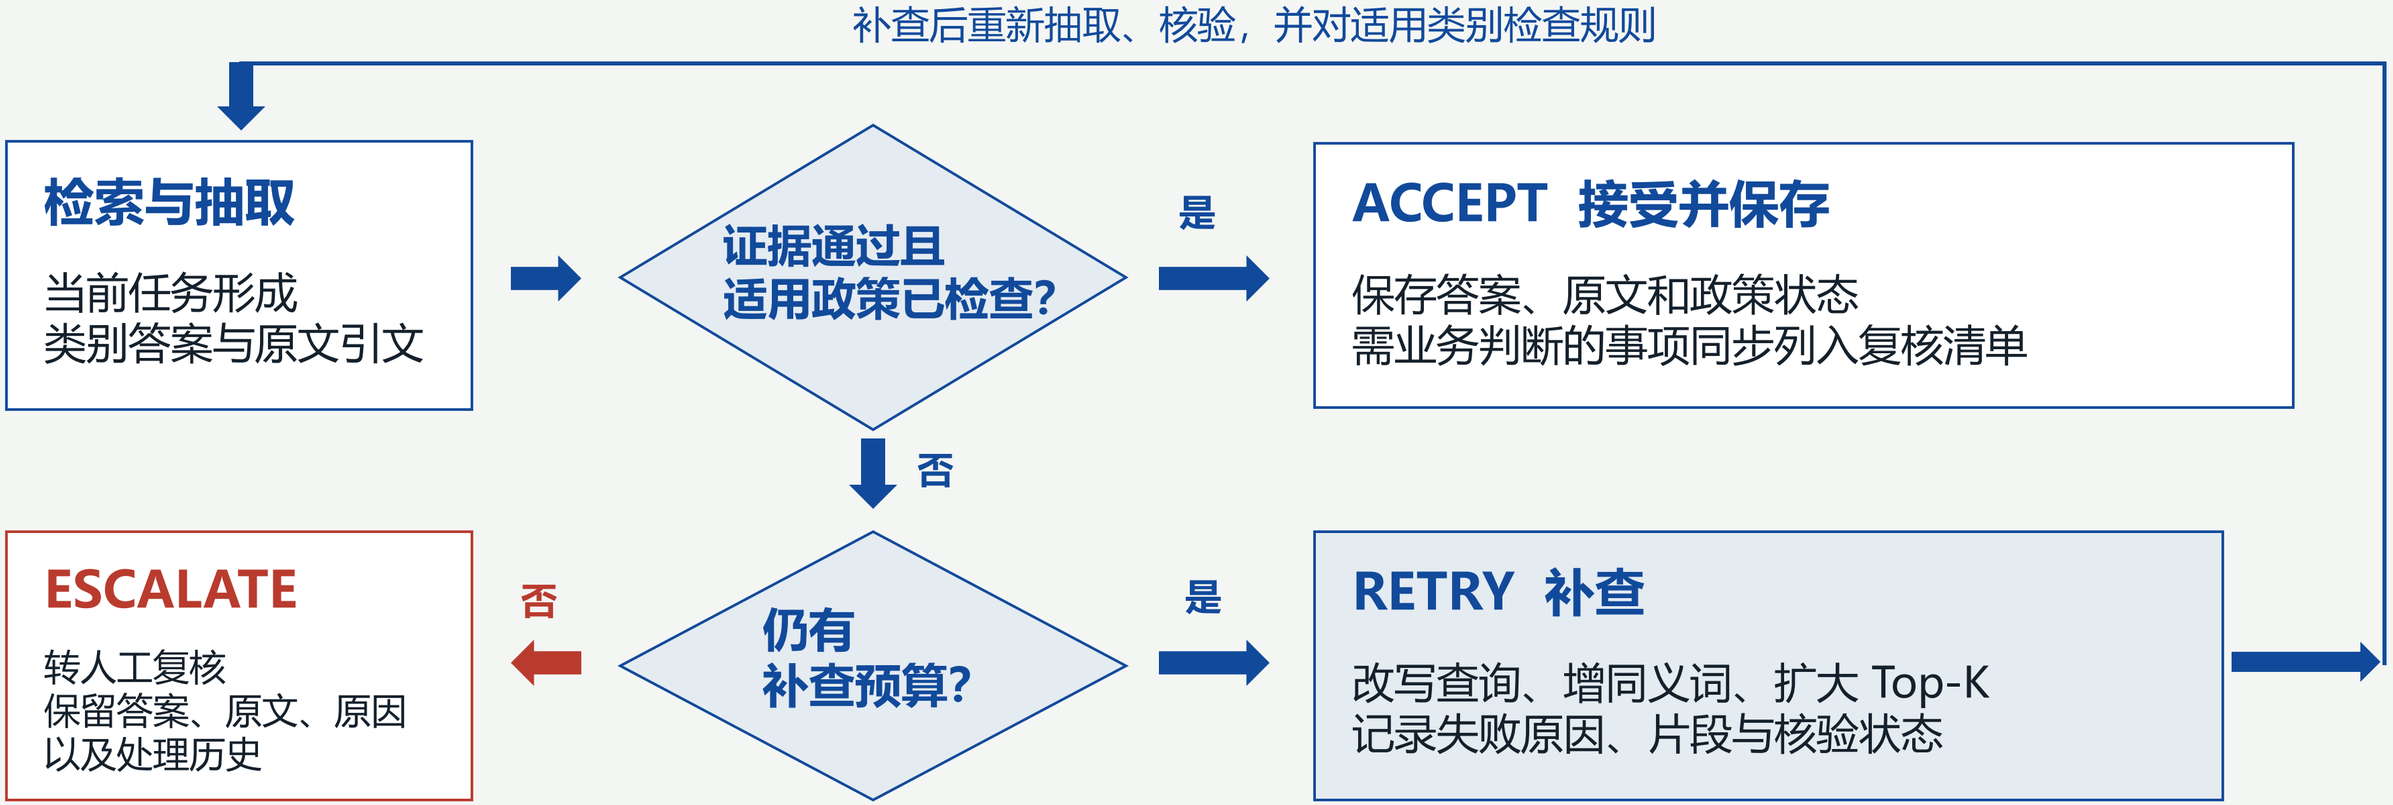
触发关注，并按配置要求人工复核

核验失败：进入补查或复核分支；事实或政策条件不足：保留“无法确认”。

目前六类规则：适用法律、续约期限、退出通知期限、保险义务、审计权、无因终止；阈值为模拟政策，非完整实测。

接受、补查与人工复核

核验反馈决定下一步，补查有预算，不确定事项有人工出口



每项任务独立记忆；首次尝试后默认最多补查两次。已触发的关注事项保留，补查用于完善证据。

运行案例

RISE Education 服务协议：用续约期限串起证据与政策提示

真实检索与位置核验

CUAD 开发侧样本：RISE Education 服务协议 • 第 13 条

This Agreement shall be renewed automatically for another five (5) years upon the expiration unless the Parties confirm, in writing, the termination of this Agreement.

13414

原始位置核验通过，可回查冻结文本

位置偏移 +5

核验失败，拒绝直接使用该引用

报告片段 • 政策为方法演示

报告字段	内容
审查类别	Renewal Term
识别结果	续约五年
合同原文	左侧第 13 条逐字引文
证据位置	起始字符 13414
政策结果	60 > 12，触发关注
人工复核	确认续约条件与交易影响

阶段演示：真实检索与位置核验；抽取含接口示例，语义通过分支为桩模型，政策比较仅说明方法。

三组对照实验设计

同一合同、同一任务和政策，比较完整方案的综合表现

统一输入：同一批合同全文、41 类任务、冻结政策与同一份输出模板

人工全量审查

人工阅读全文
记录事实、证据、政策结果
记录待确认事项和审查耗时

单次 LLM 判断

一次模型调用完成审查
不进行工具反馈补查
保存未经修改的原始输出

我们的 Agent

检索、抽取、核验与规则判断
有限补查、状态记录与汇总
输出人工复核清单

独立参考答案与统一评价：条款识别、政策执行、引用支持、单合同耗时与调用成本

控制：模型组尽量使用相同底模与参数；记录人工背景并控制样本熟悉度；上下文不足不静默截断。

待检验：相对人工能否节省时间；相对单次 LLM 能否改善质量。三组比较不单独证明某组件的贡献。

评价指标与失败场景

把质量、可靠性与成本转成可计算指标，并观察异常处理

评价维度	指标与口径	参考依据
条款识别	精确率、召回率、F1；预先明确片段匹配或重叠判据	CUAD 标注，必要时核查额外片段
政策执行	触发一致率；记录误触发、漏触发与无法确认	冻结政策与独立核对结果
证据可靠性	引用支持率；另记应提供但缺失的引用	原文位置与独立语义核查
处理代价	单合同总耗时；模型组另记调用次数	统一审查与运行日志

引用支持率 = 真实可验证且支持结论的引用数 ÷ 全部输出引用数

条件分散 / 漏检

观察是否发现覆盖不足并补查

位置错位 / 错引

观察是否拒绝直接接受

模型或工具异常

观察是否保留无法确认与原因

合同嵌入干扰指令

观察是否仍按审查要求处理

未输出引用和“无法确认”分别统计，不能当作正确或直接剔除；完整三组实验仍待运行。

共同场景使用相同合同输入；位置错位与模型不可用另作 Agent 专项故障测试。

风险治理与研究局限

说明设计措施能解决什么，以及仍然不能保证什么

风险或局限	设计措施	仍需说明的边界
合同中的干扰指令	将合同作为待审数据，限制工具权限	需要通过注入测试验证
引用正确但解释错误	位置与语义分别核验	语义模型仍可能误判
检索遗漏导致错误否定	覆盖检查、补查并保留无法确认	锚定词覆盖属于启发式依据
审核政策来源不清	记录政策版本、阈值与提示等级	模拟政策不代表普遍法律或市场标准
关注事项需业务判断	保留人工复核出口与原文依据	标记复核不代表人工已完成审核
样本代表性有限	记录来源、筛选规则与排除情况	英文公开披露合同不能直接推广至其他群体

研究结论限定于所选样本、任务、模型与政策配置，并同时报告失败情况与处理成本。

目前进展与后续计划

从已提交的模块基础推进到真实模型运行与完整比较

工作模块	当前可说明的成果	状态边界
问题与数据	场景说明、数据结构与使用边界、候选样本清单	已提交基础材料
理论与设计	理论框架、方法依据、研究假设与参考文献	已提交设计材料
Agent	架构、接口、状态、重试与人工复核流程	已形成设计
RAG	检索核验工具、测试脚本、案例与初步评测报告	模块成果
规则	六类政策检查代码、配置与接口说明	模块成果
实验与整合	已有实验设计，需统一三组并完成系统运行与比较	完整联调与三组实验待完成

排期与可检查交付

11/7
Presentation
PPT、讲稿
阶段案例、状态表

11/8—15
41 类配置与联调
覆盖清单
真实报告、日志

11/16—23
冻结样本与三组实验
原始输出、计时
参考答案、指标表

11/24—26
误漏报与复核分析
结果图表
完整案例、失败分析

11/27—30
论文、展示与复现
论文、运行说明、
文件清单

最终回答：初筛质量、证据可靠性与处理成本如何权衡，哪些事项仍需要人工判断。